
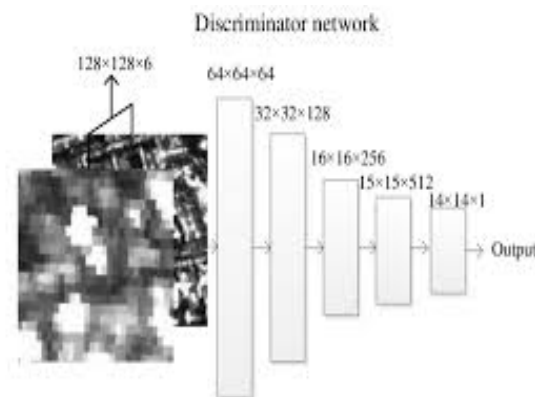


## Описание архитектуры модели

В качестве реализуемой модели была взята **CycleGAN**, а в качестве архитектуры генератора - **UNet**, архитектура ниже:



Для дискриминатора использовалась архитектура Patch Discriminator:



Функции потерь для всех экспериментов:

1. cycle loss (l1)
2. identity loss (l1)
3. adversarial loss

Также был взят измененный idt loss -  $\|G_{AB}(A)-B\|_1^1 + \|G_{BA}(B)-A\|_1^1$

Гиперпараметры:

1. learning rate - 0.0003
2. batch size - 16

Далее были проведены эксперименты на 2 датасетах в парных режимах с адверсариал функцией потерь и без. Для них замерялось l2 расстояние между целевой картинкой и сгенерированной для левого и правого датасетов.

## Эксперименты

### CityScapes

Этот датасет составлен из снимков городов, снятых на машине, и из этих же сегментированных фотографий.

Ниже представлены графики попиксельные ошибки для генерации из города в сегментированную картинку и наоборот соответственно, а также усредненная оценка от дискриминатора вероятности быть реальным изображением для сгенерированных для задачи восстановления города, где зеленый цвет - без адверсариал функции потерь, фиолетовый - с адверсариал функцией потерь (шаги считались как произведение номера эпохи и номера батча):




Сравнивая графики попиксельных ошибок при использовании дискриминатора и без его использования, видно, что качество сегментации лучше, если адверсариал потери не использовать. Качество восстановления города из сегментации выглядит одинаково плохо.


На самом правлм графике видно, что действительно, генератор обучился лучше без использования адверсариал потерь. Дискриминатор хорошо оценивает качество работы на протяжении всего обучения. И можно увидеть, что он сходится. Далее проведем качественные оценки.

### Качественная оценка

Все примеры работы модели имеют такую структуру: сначала результат работы модели, потом таргет. Сравним для начала результаты работы сегментационной части. Без дискриминатора и с дискриминатором. Как и ожидалось по метрикам, модель без дискриминатора значительно лучше обучается сегментации (картинки что выше). Так как перенос стиля не используется, то потери дискриминатора только мешает обучению модели.



Сравнивая результаты работы модели на задаче генерации города по сегментационной маске без адверсариал потерь (картинки что ниже), видно, что модель без адверсариал потерь не может улавливать черты домов, или машин, для нее они остаются пятнами, чему вполне обучается модель с адверсариал потерями. Такие различия не может улавливать просто попиксельная L2 метрика, и для их отслеживания необходимо считать другие метрики, способные улавливать не только цветовые различия.



## Edges2shoes

Датасет представляет из себя контуры ботинок и фото самих ботинок.

Ниже представлены графики PixelError. Как и с сегментацией города, задача построения очертаний не требует адвесаириал потерь, но в этом случае ее получается хорошо решить и без них, так же как и наоборот. Видно что модель быстро сходится, поэтому на ее обучение потребовалось всего 5 эпох.



### Качественная оценка

Видно, что модель решает обе задачи восстановления картинок достаточно хорошо и учитывает детали.

